Lab1 统计文章中单词的数量

李仁杰 13307130279

一、实验目的

1. 温习 C 语言的使用；
2. 练习数据结构和算法。

二、实验内容

统计文档“哈利波特_全集_.txt”中的单词，并按照出现的次数进行排序，出现次数相同的，字典序小的在前。输出到结果文件“result.txt”。

三、程序的框图

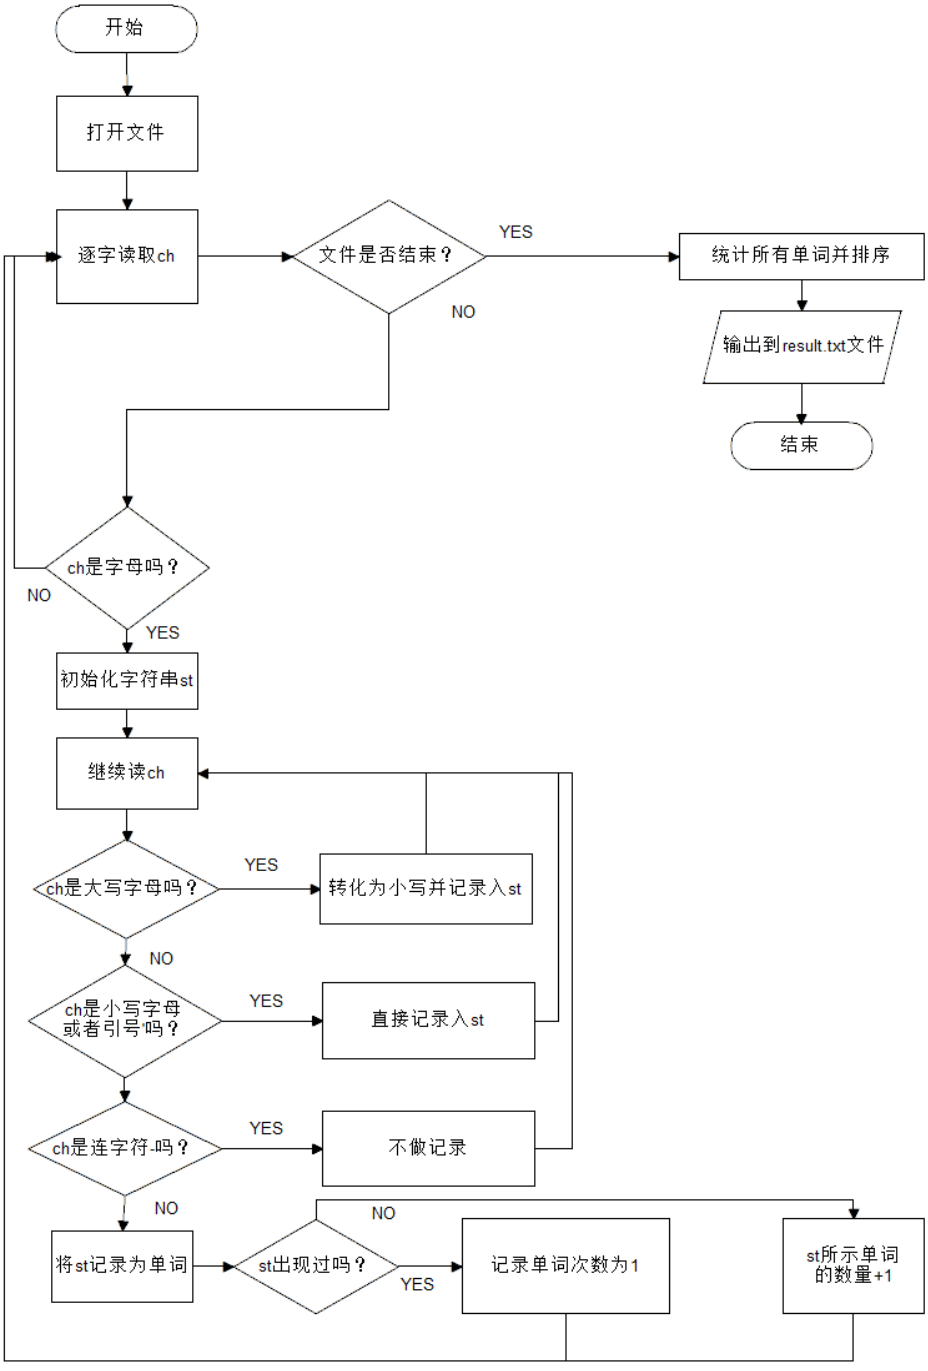

上面的程序框图是由 Diagram Designer 软件绘制。

四、程序的改进

1. 单词的查重

当出现了一个新单词，如果用顺序查找的方式检查单词是否出现，那么一次查找最坏的情况就是O(n)，n为单词的数量。对于n个单词，时间复杂度为$O(n^2)$，随着单词的数量增加，消耗的时间会非常巨大。于是这里引入哈希表进行查重。哈希表的结构为：

```
struct List
{
    char str[length];
    int flag;
    struct List *next;
};// List is a hashtable element.
```

其中 str 是字符串（单词），flag 是单词出现的次数，如果让 key 为一串哈希表的定位值，那么 hash[key]->next 就是挂在它下方的其他的链。如下图所示：

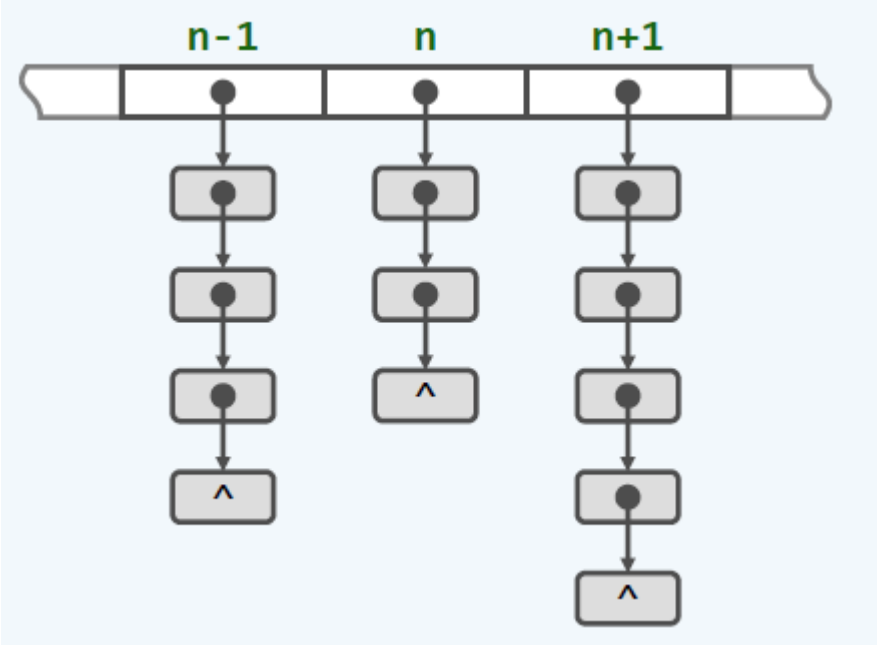

（图片来自清华大学邓俊辉的数据结构 2014 年春的教学课件）

不同的单词可能会有相同的 key 值，这里采用挂链的方式解决冲突。

对于 key 值的计算，我们采取随机数的办法，引入 sj 数组帮助计算：

```
srand(time(NULL));
for(i = 0;i < length;i++)
    sj[i] = rand() % MOD;
// sj[] is an array that can help to calculate the key value.
```

之后，对于一个长度为 len 的字符串 st，它的 key 值计算如下：

```
for(i = 0;i < len;i++)
    key = (key + st[i] - 'a') * sj[i] % MOD;
    // It means that sum st[i]*sj[i] is the key value.
```

2. 单词的排序

如果采取冒泡排序、选择排序或者插入排序，那么程序的时间复杂度可能会达到$O(n^2)$，其中n为单词的数量。为了提高这部分的效率，我们引入快速排序。我们

取单词出现的次数为第一关键字，字典序为第二关键字，进行快速排序 Qsort，时间复杂度便可下降到$O(n\log_2 n)$。

```
void Qsort(int l,int r)
```

3.程序运行时间的记录

首先我们加载<time.h>库，在程序开始的时候调用：

```
clock_t start, finish;
double during;
start = clock();
```

之后在程序结束之后调用：

```
finish = clock();
during = (double)(finish - start) / CLOCKS_PER_SEC;
```

即可得到程序的运行时间。

五、程序运行结果

运行结果在附件中的“result.txt”文件中。

运行总时间为：1.146second(s)。(Linux Ubuntu 14.04 系统)

六、实验总结

首先，在这次实验中，我温习了 C 语言的字符串、链表和排序的知识；其次，因为程序需要多次改进，为了记录程序的每一个版本，我学习了 github desktop 的使用——这也使得我的效率显著提高，我的代码文件“Count_Words.c”也会在 Lab1 截止时间之后开源（https://github.com/lirenjie95/CSAPP）；最后，我也在实验中基本掌握了 Linux 系统的使用。